

# 青年AI 自强项目—学生活动

序号	讲座/活动主题
1-讲座	AI鸟瞰与升级指南
2-讲座	机器学期入门
3-讲座	经典神经网路
4-讲座	深度神经网络
5-讲座	卷积神经网络
6-讲座	分类任务
7-讲座	探测任务
8-讲座	实例与调参
9-任务	转化挑战

核心逻辑一学生统筹数据院资源培养学生

免费学生活动一希望大家包容



#### **林** 末大学 | 数据科学研究院

Institute for Data Science

### 青年AI自强项目 的组织形式







原则上对参与的学生不设



#### 师兄主笔

统筹资源,产出核心内容.



#### 大咖把关

对学术内容的质量把关



#### 小姐姐易读

文科小姐姐对易读性把关



**王建民** 数据院副院长, 教授, 软件学院院长

王建民院长: 把握住数据院的出发和落脚点 把握住数据院优势





**韩亦舜** 执行副院长

韩亦舜院长: 希望大家守住情怀 成为复合人才

培养"跨学科应用型高层次人才"是数据院的使命。由于我们招收的学生不分专业背景,接受一些新名词、新概念、新技术,对没有多少信息学科背景的同学来说,的确挑战很大。幸好在学生大数据协会的推动下,形成了"大牛师哥师姐帮助零基础的学弟学妹尽快入门并进阶"的良好传统。

学生大数据协会的研究部还组织撰写了"一文读懂"系列文章,帮助有需要的人入门。 这次的"AI人才培养项目"旨在帮助那些想学习人工智能又苦于没有基础的在校同学和在职人员入门。 课程设计以问题为导向,重在培养大家的入门级动手能力。

人工智能作为挖掘大数据价值的工具之一,相关人才也是紧俏难求。希望我们提供的这个交流平台, 能够对大家有帮助。希望随着技术的发展,大数据、人工智能等新领域、新技术,不再高居庙堂之上, 而是能够帮助大家的工作和生活。

# が 事大学 数据科学研究院 Tsinghua University Institute for Data Science 数 括派研究音

王明哲

教学资源

组织成员 产出内容 数据 派

行业资源.

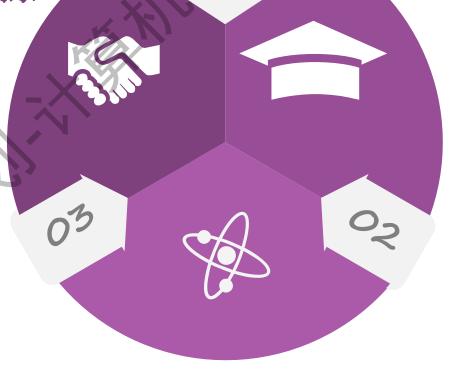
航天 五院

孵化中心

AI在航天的 落地应用

自动化系 非全研究生

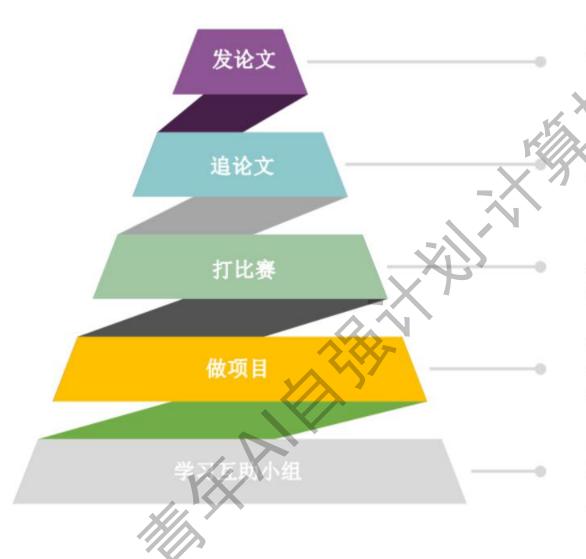
17级 MEM



科研资源



### 进阶实践



保持学术高度

在数据院的资源条件下完成工作.

学术热点追踪

为发论文做好充足的准备

快速实践进步

代表数据院参加各类比赛,在比赛之中快速磨炼,快速成长

实践推动型学习

基于数据院已有的成功教学项目,或者额外的企业真实需求项目

打基础系列活动

有共同科研爱好方向的同学组成学习小组, 定期聚会讨论,互相促进提升







4

15min

作业说明



# AI热潮及AI难点



AI热潮

新手不友好

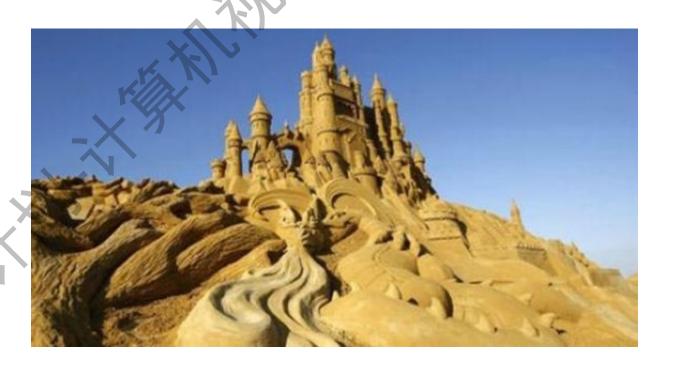
知识结构复杂

#### 1950年, 图灵发表了一篇划时代的 人工智能的诞生 论文,并提出了著名的"图灵测试" (1943-1956) 1956 年达特茅斯会议:AI 的诞生 符号主义 早期推理系统 早期神经网络(联结主义) 1950-1970年的早 智能计算机程序系统, 其 期发展热潮 内部含有大量的某个领域 专家水平的知识与经验、 专家系统 能够利用人类专家的知识 和解决问题的方法来处理 该領域问题。 "AI之冬"之后, 语音识 统计学派 别领域统计学派取代专 专门研究计算机怎样模拟或 1980-2000年的第 实现人类的学习行为, 以获 二次发展热潮 机器学习 取新的知识或技能。重新组 织已有的知识结构使之不断 改善自身的性能。 1、人工智 神经网络用语模式 神经网络(联结 能的历史 主义重获新生) 识别等任务 指无法在一定时间范围内 用常规软件工具进行插 大数据广 泛应用 能具有更强的决策力、洞 察发现力和流程优化能力 的海量、高增长率和多样 通过组合低层特征形成更 加抽象的高层表示属性类 2006年之后的第三 别或特征, 以发现数据的 次发展热潮 分布式特征表示 机器视觉、语音识别、机 深度学习 器翻译等领域深度学习的 强化学习、迁移学习。 生成对抗网络等新技术 的发展。 (非深度) 机器学习 AlphaGo 为标注的大众传播

### 学校专业课程 火爆但难懂

# AI现有入门办法



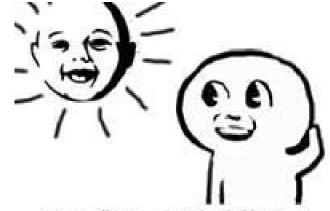


博客、论坛、网站 品质随机、不成体系

## 课程目标

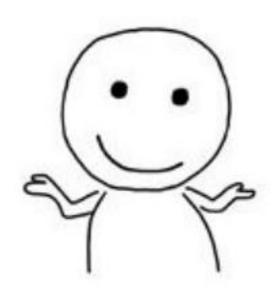
新華大学 | 数据科学研究院 Tsinghua University | Institute for Data Science

### 跨越两个鸿沟 具备进阶能力



阳光下的懵逼 Mengbi Under the Wuke

老师觉得你懂



距离实践远

# 知识的魅力

$$\arg\min F\left(\mathcal{D};\theta\right) = \mathcal{L}\left(\left\{x_{i},y_{i}\right\}_{i=1}^{n};\theta\right) + \Omega\left(\theta\right)$$

理工科知识不友好穿越感受知识魅力





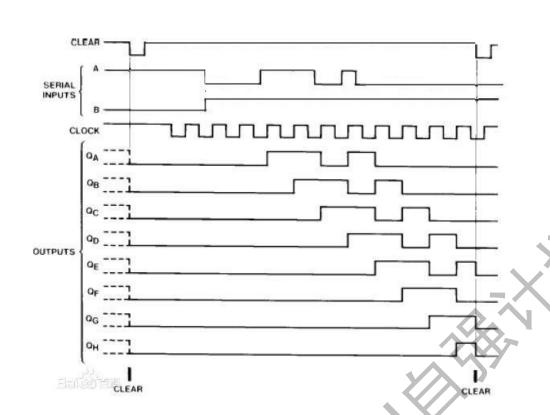


二进制VS十进制

偶蹄目

"智猪"

# 知识的魅力



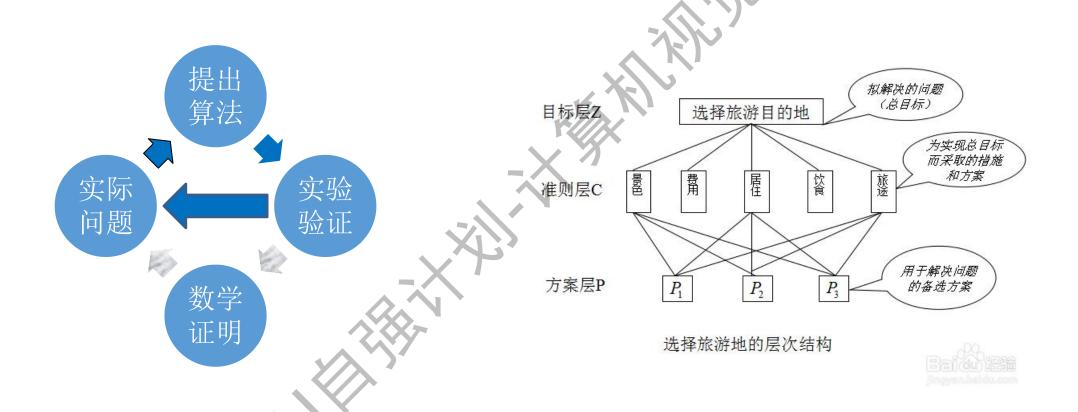


机器有几根手指?

强行十进制?



# 知识产生的规律



知识的产生规律

数学证明不必须



# 专注学术的问题

我是谁?

我是怎么考进来的?











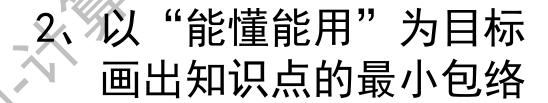
他们怎么什么都会?

老师授课

每日三问

## 本次授课的逻辑





3、尽量说"人话" 不用学术词汇吓唬大家

三项原则



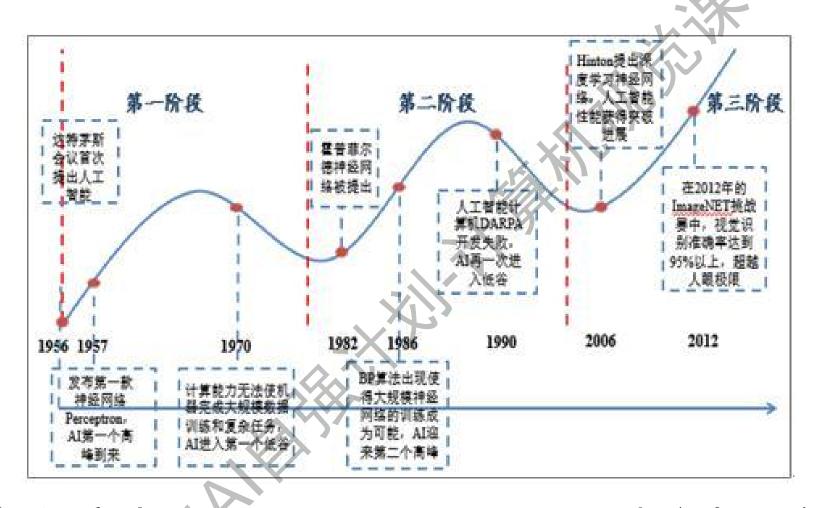








### AI回顾



人工智能产生-1956&1950 三波浪潮一个目标: 让机器变像人那样聪明



### AI回顾





采集外部世界的数据

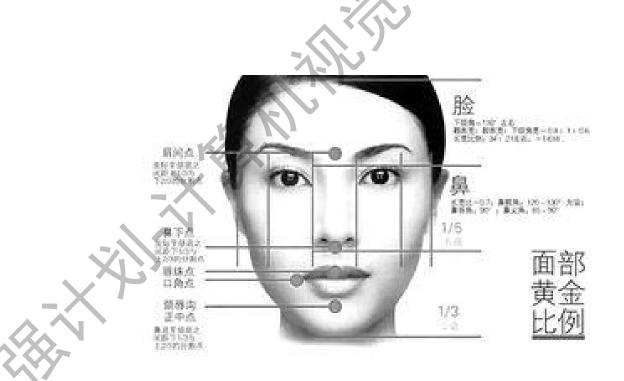
通过执行决策来反馈外部世界

智能产生的过程



# 感知过程





人的五感

五个感受器官

五种感知数据







计算机的感受器官?

计算机的感知数据已经是"大数据"



## 感知数据

数据采集及存储、管理



数据清洗及 标注

数据建模



数据可视化

买菜/偷菜

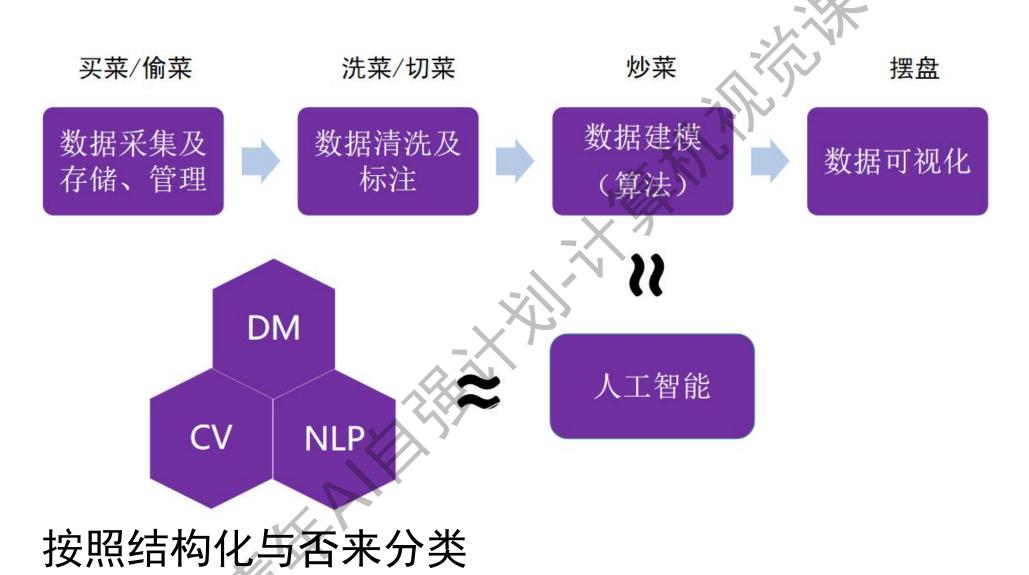
洗菜/切菜

炒菜

摆盘

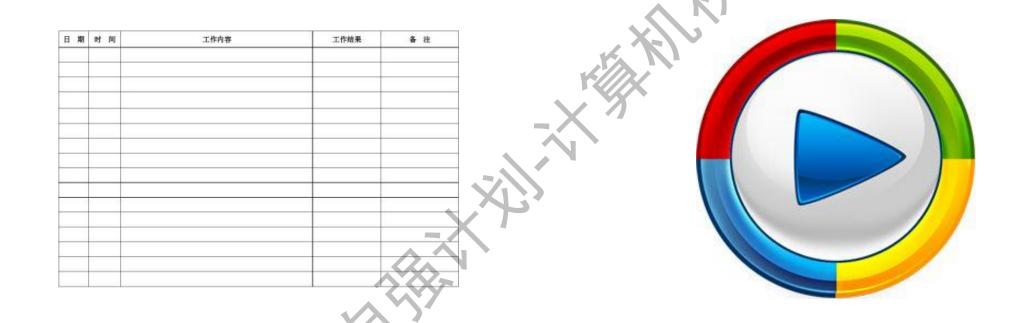
大数据工作流程回顾与云计算的关系?

# 新華大学 数据科学研究院 Institute for Data Science A I 是大数据关键一步





# 数据科学研究院 Institute for Data Science 什么是结构化数据?



结构化数据-统计学算法处理

非结构化数据-DNN处理 关键难点影响了AI兴衰



## 感知小结



感知不是关键,认知才是

举例: 野生哺乳动物与人



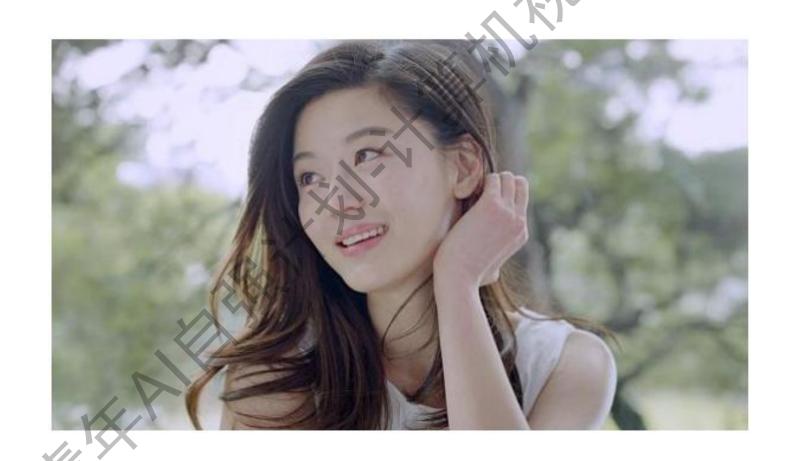
# 认知概述

推理 第二步 抽象提炼 第一步 提取关键信息 认知的三个层次



# 数据科学研究院 Institute for Data Science <del>大力</del>从知的小例子

# 约到了暗恋已久的妹子



# 计算机感知靠算法

新華大学 | 数据科学研究院 Tsinghua University | Institute for Data Science

人工智能算法的本质:

找到一些特征,来描述一些数据/问题,并做出一些预测。

解读"约妹子"的小例子

用一个小剧透帮助理解原理

## 什么样的男生受欢迎

が オメ 学 | 数据科学研究院 Tsinghua University | Institute for Data Science

选取特征 --> 收集样本 --> 标注 --> 拟合 --> 预测

手动选择特征 遇到 非结构化数据 = 难点

原因: 手动特征最多两位数, 非结构化数据特征点数以万计

## 图像为例



黑色 (0, 0, 0)

白色 (255, 255, 255

美术原理

文艺科学家

# 计算机VS人眼





What We See

人类看到的



What Computers See

计算机看到的

# 人类认知图像的效果







at.7253.jpg\_shape:(375, 499, 3)



dog.11264.jpg\_shape:(374, 500, 3)













知乎@岱峰

小实验,效果惊人



# が著えず 数据科学研究院 Institute for Data Science 人类认知图像的原理





哪个是虎皮猫,哪个是小老虎呢?

纵览全局,自动提取特征,自动拟合

# 为什么机器很笨?

1、可用于拟合的特征点实在太多

2、特征表示的局限性 = 贴脸看照片

3、不能自动选择特征

#### 2012-2017

# 划拨沉寂的惊雷





AlexNet

"大型的深度卷积神经网络" CNN

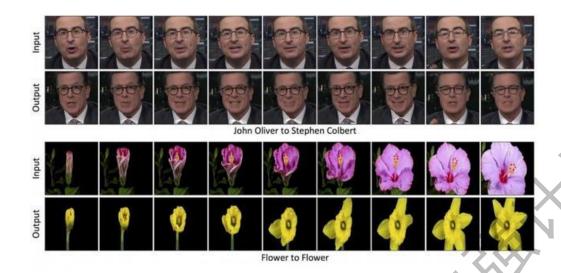
ImageNet: 数据集

ILSVRC: 比赛

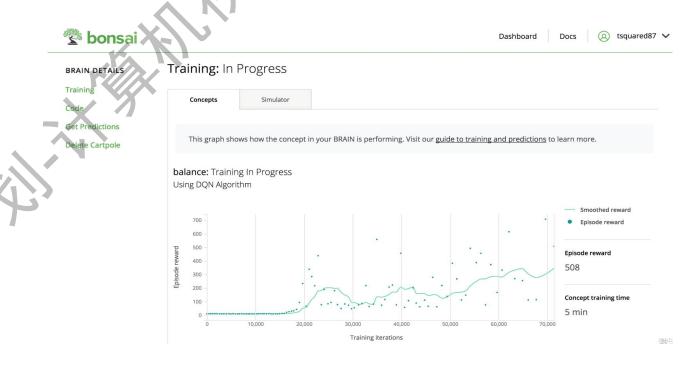








"软输入":GAN (2014)



"硬输出": 增强学习(2016)

1、所有突破都仅限深度神经网络

总结

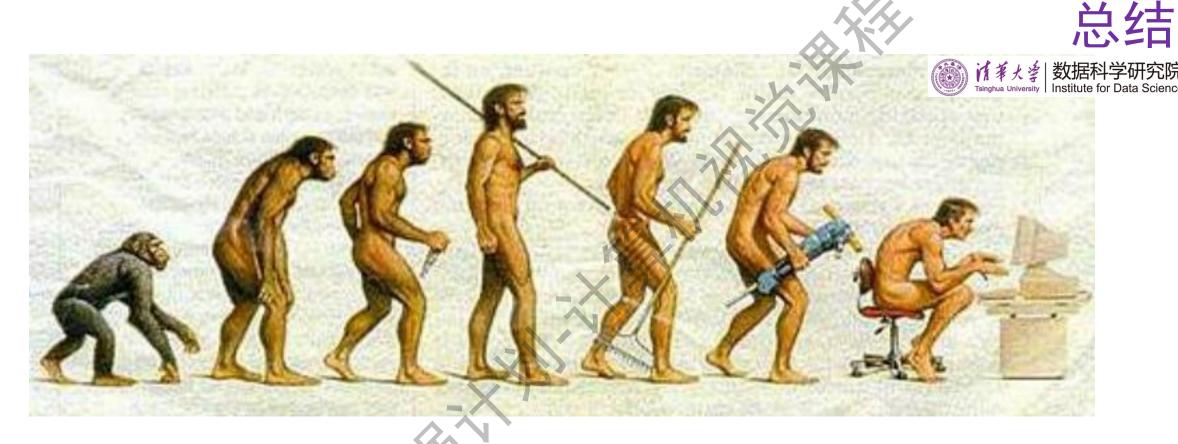


2、极大地资源开销

3、NLP问题解决的仍不够好,三分类举例。

原因=智力发展的规律。

观点:人类文明承载与语言;异议一>小实验



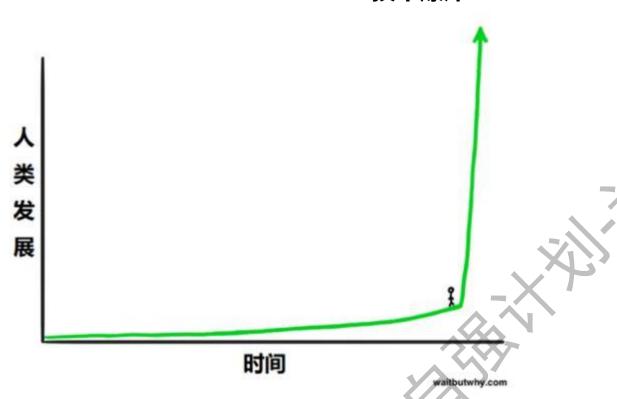
- 4、目前机器的认知仅仅止步于第一个层次 后两个层次才是高等智力的屏障。
- 5、最容易落地的技术当属计算机视觉

# 第二部分: 进阶办法

共享开源









技术变现的手段:

从前,现在?

从不同等级人才的角度考虑问题:

前沿团队,人才梯队?

## が Tsinghua University Institute the state of the state

**菜鸟筑基:**本阶段的人才以大数据基础理论的学习为主,尚不能胜任 真实的项目或者工作;

**初入江湖:**本阶段的人才已经具备了初步的大数据实践的能力,建议通过实践(做项目、打比赛等)来更好地带动学习;

**登堂入室:**本阶段的人才需具备大数据科研论文的调研、阅读和理解能力,能够成功地将论文中的算法进行复现;

**华山论剑:**本阶段的人才能够独立地开展大数据新技术的研究工作, 具有发表原创性论文的能力。



最好的资源往往是公开的













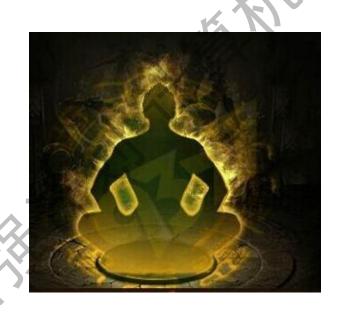
gitxiv



# . 最好的资源往往是公开的



英语是"用"的不是"学"的



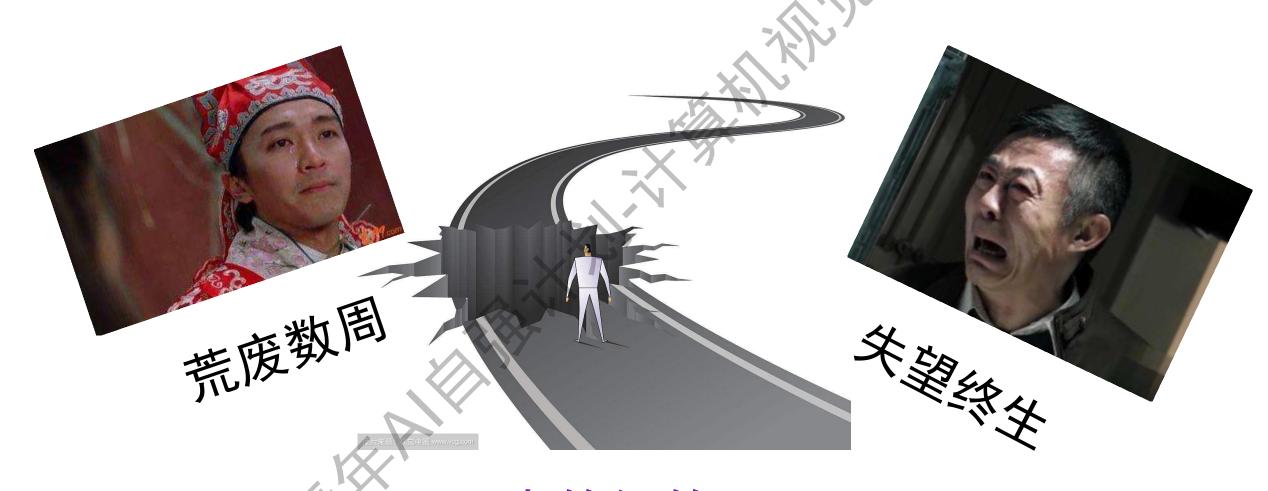
内功=算法



外功=代码

# 2. 不要看书、不要看书、不要看书

菜鸟筑基



真的假的?



#### 卷积的学术定义

卷积是两个变量在某范围内相乘后求和的结果。如果卷积的变量是序列x(n)和h(n),则卷积的结果为

$$y(n) = \sum_{i=-\infty}^{\infty} x(i)h(n-i) = x(n) *h(n)$$

其中星号\*表示卷积。当时序n=0时,序列h(-i)是h(i)的时序i取反的结果;时序取反使得h(i)以纵轴为中心 翻转180度,所以这种相乘后求和的计算法称为卷积和,简称卷积。另外,n是使h(-i)位移的量,不同 的n对应不同的卷积结果。

如果卷积的变量是函数x(t)和h(t),则卷积的计算变为

$$y(t) = \int_{-\infty}^{\infty} x(p)h(t-p)dp = x(t) * h(t)$$

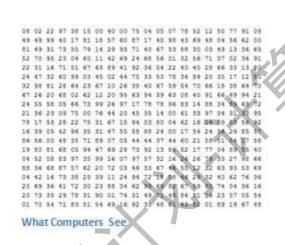
其中p是积分变量,积分也是求和,t是使函数h(-p)位移的量,星号\*表示卷积。

参考《数字信号处理》杨毅明著, p.55、p.188、p.264, 机械工业出版社2012年发行。

### 一分钟弄懂卷积运算(一点都不学术)



What We See



简化后的图片

1	1	1	0	0
0	1	1	1	0
0	0	1	1	1
0	0	1	1	0
0	1	1	0	0

×1	×0	×1
×0	×1	×0
×1	×0	×1

简化后的卷积核



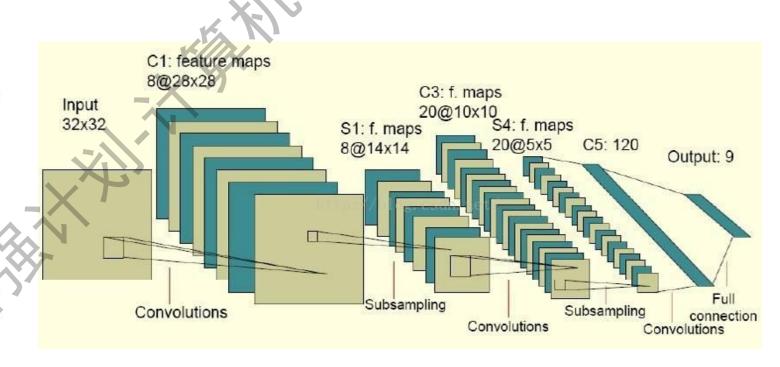
#### 从左到右, 从上到下扫一遍

1,	1,0	1,	0	0
0,0	1,	1,0	1	0
0,,1	0,0	1,1	1	1
0	0	1	1	0
0	1	1	0	0

**Image** 

4		22	0
		- 35	- 8
	33	0.0	- 3

Convolved Feature



卷积神经网络



第1章引言1

第1部分应用数学与机器学习基础

第2章线性代数

2.1标量、向量、矩阵和张量19

2.2矩阵和向量相乘21

2.3单位矩阵和逆矩阵22

2.4线性相关和生成子空间23

2.5范数24

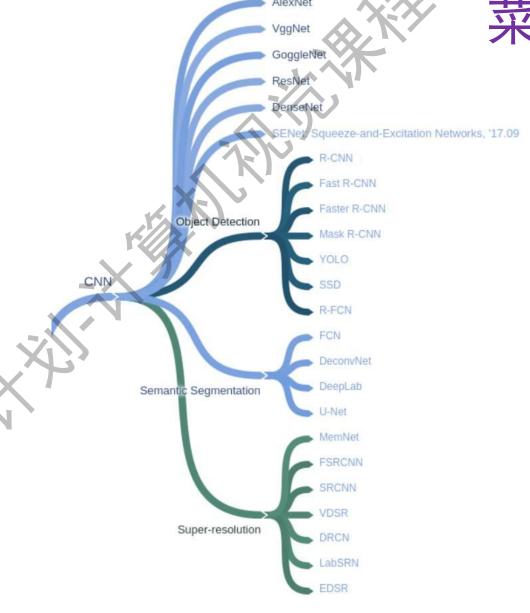
2.6特殊类型的矩阵和向量25

2.7特征分解26

2.8奇异值分解28

.....

共500页



目前发展现状

某热销学术专著目录



- 1、已有明确研究方向
- 2、已有高人指路给出必读书目
- 3、不求"甚解"



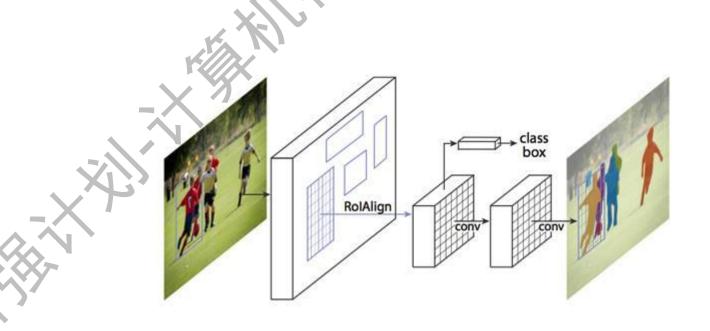
而是用来"查" 好书不是用来 "啃" 的, 的



## 3. 找对好基友,连滚带爬往前走



推翻了BP算法的BP 算法之父



发best paper像一般人发paper一样容易的神奇学霸

## 本阶段总结

## 不要停留太久,建议:

偏AI方向完成《深度学习》课程

偏DM方向完成《机器学习》课程

后即可进入下一阶段展开实践



## . 找到一个最高的baseline



"baseline"可以理解为前人已经做出成果, 当自己恰好需要去做相同工作时的参照。



1. 找到一个最高的baseline











对某"类"问题无从下手

对某"个"技术不明所以



2. 合理追求quick win



为什么女生能够"不知疲倦的逛街?"



3. 你最大的动力往往来自DDL (Deadline)





3. 你最大的动力往往来自DDL



(Deadline)



## 一一初入江湖 进入下一阶段的小建议

1、"大数据"并不等于"数据大";

2、再次强调baseline,"拿来主义"不可耻

3、切记生搬硬套,针对性的改进=创新



# 登堂入室及华山论剑

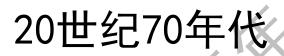
## . 朋友圈决定了你人生的高度

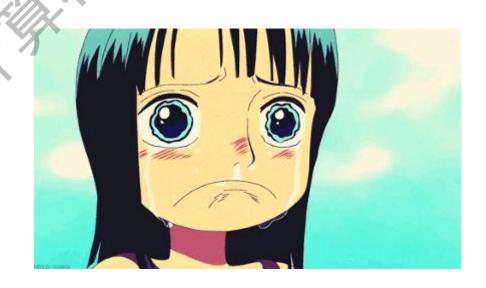






# 登堂入室及华山论剑 2. 选择永远比努力更重要





20世纪90年代



# 登堂入室及华山论剑

# 3. 唯一的限制往往是自己的妥协





华山之巅背后的秘密





扫码加好友进群